

Proyecto de Transfer Learning y Fine Tuning

Descripción genera:

El proyecto consiste en desarrollar un sistema de análisis de sentimientos y clasificación de reseñas turísticas en español. Este reto está inspirado en el desafío REST-MEX 2025, que utiliza reseñas reales de turistas a los Pueblos Mágicos de México.

Objetivo general:

Diseñar, implementar y evaluar un modelo de aprendizaje profundo capaz de:

1. Clasificar el **sentimiento** de una reseña turística en una escala de muy negativo (etiquetado con 1) a muy positivo (etiquetado con 5).
2. Identificar el **tipo de lugar** al que se refiere la reseña (hotel, restaurante o atractivo).
3. Reconocer el **Pueblo Mágico** donde se hizo esa reseña (de 40 posibles pueblos mágicos en el dataset).

Conjunto de datos (dataset)

Para el desarrollo del proyecto se proporcionarán dos versiones del conjunto de datos. Cada versión contará con:

- Datos de entrenamiento
 - a. Contienen las reseñas con sus etiquetas correctas (sentimiento, tipo de lugar y Pueblo Mágico).
 - b. Sirven para entrenar los modelos y ajustar los algoritmos.
- Datos de prueba
 - a. Contienen solo el texto de las reseñas, **sin etiquetas**.
 - b. Se utilizarán para evaluar los modelos.
 - c. Las etiquetas correctas se mantienen **ocultas para los participantes** para que la validación se realice comparando las predicciones del sistema con las etiquetas reales.

Angel Ramón Aranda Campos
CIMAT
arac@ciat.mx

1. Versión reducida:

- Incluye una pequeña muestra de las reseñas con sus etiquetas del Rest-Mex 2025.
- Su propósito es que los participantes puedan explorar rápidamente los datos, probar ideas iniciales y validar el flujo de trabajo sin necesidad de usar muchos recursos computacionales.
- Los datos se pueden descargar de la liga:
<https://drive.google.com/file/d/1VNiHnom0bLGke1IIH3oetZbvVreencPF/view>

2. Versión completa:

- Contiene todas las reseñas disponibles de la tarea internacional del Rest-Mex 2025.
- Está pensada para entrenar los modelos finales y obtener mejores resultados.
- Los datos se pueden descargar de las siguientes ligas:
 - Entrenamiento:
https://drive.google.com/file/d/1xf0nGF29hFWBg_rXSJoFGcq86T9ekit8/view?usp=sharing
 - Pruebas:
https://drive.google.com/file/d/1k9s0_4D0vvfLYiCzcGfzRE9_yU1L_BTW/view?usp=sharing

IMPORTANTE: Uno de los retos principales de estos datasets, es que los datos están completamente desbalanceados. Aunque la idea de este proyecto, como parte del diplomado, es desarrollar un sistema donde se aplique un modelo de Deep learning y no atacar el problema de desbalanceo como tal (opcional), siempre hay que realizar un análisis preliminar de los datos para así poder desarrollar modelos que se adecuen a los mismos datos.

Formato de salida

El sistema desarrollado debe generar, para cada tarea del conjunto de datos, un archivo de texto (.txt) que contenga una línea por cada instancia clasificada (por cada reseña de la base datos de prueba). Cada línea debe seguir exactamente este formato (sin comillas):

```
"TaskName" \t "IdentifierOfAnInstance" \t "Classes" \n
```

Angel Ramón Aranda Campos
CIMAT
arac@ciamat.mx

Nota: Es importante respetar el uso de:

- El tabulador “\t”
- El salto de línea “\n”

Detalles:

- TaskName: pueden poner cualquier cosa, como sus iniciales.
- IdentifierOfAnInstance: corresponde al número de opinión (la línea en el archivo de prueba).
- Classes: se deben predecir tres elementos separados por tabuladores (\t):
 - Valor de sentimiento: número entero del 1 al 5
 - Pueblo Mágico: uno de los nombres de la lista (40 posibilidades)
 - Tipo de destino: una de las categorías Attractive, Hotel o Restaurant

Ejemplo del archivo de salida esperado para los datos de prueba:

rest-mex	0	5	Sayulita	Restaurant
rest-mex	1	4	Bacalar	Attractive
rest-mex	2	1	TodosSantos	Restaurant
rest-mex	3	3	Isla_Mujeres	Hotel

En este ejemplo, solo se muestran 4 instancias procesadas, pero en el archivo final, deben estar la cantidad de instancias contenidas en las bases de datos de **pruebas**.

Retroalimentación y seguimiento

Puedes contactarme por correo (arac@ciamat.mx) en cualquier momento para dudas. También puedes enviarme, en cualquier momento, los archivos de salida que vaya generando tu sistema (ya sean de los datos reducidos o de los datos completos). Con ellos podré evaluarte de manera preliminar y darte retroalimentación para que sepas cómo está funcionando tu modelo antes de la entrega final.



Angel Ramón Aranda Campos
CIMAT
arac@ciamat.mx

Referencias y sitio oficial del reto

Si quieres adentrarte en más detalles e información sobre el reto visita:

<https://sites.google.com/cimat.mx/rest-mex-2025/>